中正大學

宇宙工程研究所碩士論文

結合動態重加權與特徵正交化之長尾影像分類研究

Long-Tail Image Classification via Dynamic Re-weighting and Feature Orthogonalization

研究生：王小明

指導教授：李天才教授

中華民國 114 年 9 月

摘要

本研究探討以深度學習方法改善多分類影像辨識之效能。近年卷積神經網路在多種視覺任務上展現優異表現，然而在資料量受限與類別不平衡 (class imbalance) 的情況下，傳統訓練流程容易造成某些少數類別辨識率偏低。為解決此問題，本研究提出一個結合動態類別重加權 (dynamic re-weighting) 與特徵正交化 (feature orthogonalization) 之訓練框架，於保持整體精確度的同時提升長尾 (long-tail) 類別之召回率。實驗以公開資料集與自建小型資料集進行驗證，結果顯示相較基準模型，所提方法在 Macro-F1 及少數類別 Top-1 準確率均有顯著提升。最後，本研究並分析特徵空間分佈，證實特徵正交化有助於降低類別間干擾。

本論文之主要貢獻包含：(1) 提出一套可即插即用之動態類別權重調整策略；(2) 引入特徵正交化損失於長尾分類場景；(3) 於多組資料集與不同網路骨幹下驗證方法之穩健性；(4) 釋出實驗程式碼以利後續研究延伸。

關鍵詞：深度學習、長尾學習、特徵表徵、卷積神經網路

Abstract

This thesis investigates a training framework to improve class-imbalanced multi-class image classification under limited data regimes. Although modern convolutional neural networks achieve strong performance, minority classes in long-tail distributions often suffer from poor recall. We propose a plug-and-play framework that combines dynamic class reweighting with feature orthogonalization to mitigate inter-class interference while preserving global accuracy. Experiments on public and proprietary datasets demonstrate consistent gains in Macro-F1 and minority-class Top-1 accuracy over strong baselines. Feature space visualization further confirms that orthogonalization encourages better inter-class separation.

The contributions are: (1) a dynamic weighting strategy adaptive to per-epoch class difficulty; (2) incorporation of a feature orthogonalization loss tailored for long-tail settings; (3) comprehensive evaluation across multiple backbones and datasets; (4) public release of reproducible code.

Keywords: deep learning, long-tail learning, feature representation, convolutional neural networks

誌謝

本論文能順利完成，首先衷心感謝指導教授李天才教授，在整個研究期間給予我耐心指導、嚴謹學術訓練與方向上的啟發。老師在問題拆解、實驗設計與結果分析上的建議，使我得以逐步建⌧獨⌧研究與批判性思考能力。

亦感謝口試委員在論文審查時所提出的寶貴意見，協助我釐清研究假設並提升論述完整性。感謝實驗室的學長姐與同儕，於資料標註、環境設定與程式除錯上給予協助與討論；特別是一起度過深夜實驗與多次模型重訓的時光，讓研究路途更加踏實。

感謝家人長期無條件的支持與鼓勵，成為我面對研究瓶頸時最堅實的後盾。若無家人的體諒與支持，我難以專注於學術進程。

此外，本研究部分實驗使用系上計算資源與開放資料集，特此誌謝。若本文仍有不足與疏漏，均由本人自行負責。

王小明

國⌧中正大學資訊工程研究所

中華民國 114 年 9 月

目　錄

摘要 i

Abstract ii

誌謝 iii

第一章　緒論 1

1.1 研究背景 1

1.2 研究動機 1

1.3 問題定義 1

1.4 研究目的與貢獻 2

1.5 章節安排 2

第二章　文獻探討 3

2.1 長尾學習 3

2.2 表示學習強化 3

2.3 綜合分析 3

第三章　資料及研究方法 4

3.1 資料與前處理 4

3.2 模型架構 4

3.3 動態類別重加權 4

3.4 特徵正交化損失 5

3.5 訓練流程演算法.....**5**
3.6 時間複雜度.....**6**
3.7 程式碼片段示例.....**6**
第四章　實驗結果.....**7**
4.1 實驗設定.....**7**
4.2 評估指標.....**7**
4.3 比較方法.....**7**
4.4 主要結果.....**7**
4.5 消融研究.....**8**
4.6 特徵可視化.....**8**
4.7 討論.....**9**
第五章　結論.....**10**
參考文獻.....**11**
附錄.....**12**

圖　次

圖 4-1　　消融分析示意 (示意圖以浮水印代替)。 8

表　次

表 4-1　　主要分類績效 (公開資料集).....8

第一章　緒論

本章說明研究背景、動機、問題定義、研究目的與貢獻，最後介紹章節安排。

1.1　研究背景

近年來，深度學習模型於影像分類、語音辨識與自然語言處理皆展現突破性成果。然而在實務資料中，類別常呈現長尾 (long-tail) 分佈：少數常見類別擁有大量標註，罕見類別標註則極為有限，導致標準交叉熵訓練偏向多數類別。為改善此問題，過往方法包括重新取樣、損失重加權與表示學習強化等策略。文獻顯示適度的類別權重與特徵結構化能提高少數類別之召回率 [1, 2]。

1.2　研究動機

傳統固定權重策略忽略類別於訓練過程中的難易度變化；同時，類別間特徵投影重疊會削弱分類邊界。若能結合動態調整權重與約束特徵方向，可望同時提升整體精確度與少數類別表現。

1.3　問題定義

給定一組帶有標籤之影像資料集 $\mathsf{D} = \{(x_i, y_i)\}_{i=1}^{N}$，其中 $y_i \in \{1, \ldots, K\}$，類別出現頻率高度不均。目標為訓練一個分類模型 f_θ 以最大化長尾場景下之整體效能 (如 Macro-F1) 與少數類別 Top-1 準確率，同時避免多數類別顯著退化。

1.4 研究目的與貢獻

本研究之主要貢獻如下：

(1) 提出動態類別重加權：依每個 epoch 之錯誤率與支持度調整有效權重。

(2) 引入特徵正交化損失：降低不同類別特徵向量之內積相關性。

(3) 系統性實驗：跨多組資料集與骨幹網路驗證泛用性。

(4) 釋出程式碼與設定，提升可重現性。

1.5 章節安排

第 第二章 章回顧相關工作；第 第三章 章詳述方法；第 第四章 章呈現實驗設計與結果；第 第五章 章總結並提出未來方向；附錄補充理論推導與額外圖表。

第二章　文獻探討

本章整理長尾分類 (long-tail classification) 與特徵表示正規化之相關研究。

2.1　長尾學習

長尾資料造成標準訓練偏差。常見策略包含：過取樣少數類別、欠取樣多數類別、損失重加權與調整 logits 後處理。重加權方法中，靜態類別權重通常以反頻率或有效樣本數 (effective number) 計算，然而無法反映訓練進程中難度動態。

2.2　表示學習強化

為提升特徵可分性，文獻提出中心損失 (center loss)、角距離損失與正交化約束。透過限制類別中心間相關度，可使決策邊界更為清晰。本研究採用一個輕量正交化項，與分類損失聯合最佳化。

2.3　綜合分析

現有方法多聚焦於單一面向。本研究結合動態權重與正交化，形成互補：前者調整梯度貢獻，後者改善特徵幾何結構。相關背景也可參考 LaTeX 相關排版工具說明 [3] 以撰寫論文。

第三章　資料及研究方法

本章介紹資料前處理、模型架構、動態重加權策略與特徵正交化損失。

3.1　資料與前處理

原始資料集含 K 個類別，類別樣本數差異可達兩個數量級。前處理包括：影像縮放至 224 × 224、隨機水平翻轉、色彩抖動與正規化。另於驗證與測試階段僅採中心裁切。

3.2　模型架構

骨幹網路採 ResNet-50 作為主要實驗基礎，記特徵抽取函數為 $g_\theta(x) \in \mathbb{R}^d$，分類頭為線性層 $W \in \mathbb{R}^{K\times d}$，預測機率：

$$p(y=k \mid x) = \frac{\exp(W_k g_\theta(x))}{\sum_{j=1}^{K} \exp(W_j g_\theta(x))}. \tag{3.1}$$

3.3　動態類別重加權

定義 epoch t 時類別 k 的錯誤率為 $e_k^{(t)}$，樣本數為 n_k。調整後權重：

$$w_k^{(t)} = \frac{(e_k^{(t)} + \epsilon)^{\alpha}}{(n_k)^{\beta}} / Z^{(t)}, \quad Z^{(t)} = \sum_{j=1}^{K} \frac{(e_j^{(t)} + \epsilon)^{\alpha}}{(n_j)^{\beta}}, \tag{3.2}$$

其中 α, β 控制錯誤率與支持度影響力，ϵ 為平滑常數。分類損失：

$$L_{cls} = -\sum_{i=1}^{N} w_i^{(t)} \log_{\hat{y}} p(y_i \mid x_i). \tag{3.3}$$

3.4 特徵正交化損失

記類別中心 $c_k = \frac{1}{|D_k|} \sum_{(x_i, y_i = k)} g_\theta(x_i)$，構造正交化項：

$$L_{ortho} = \frac{1}{K(K-1)} \sum_{k \neq j} \left(\frac{c_k^T c_j}{\|c_k\| \|c_j\|} \right)^2 . \tag{3.4}$$

總損失：

$$L = L_{cls} + \lambda L_{ortho}. \tag{3.5}$$

3.5 訓練流程演算法

演算法 3.1 描述整體訓練程序。

Algorithm 3.1 動態重加權與特徵正交化訓練流程

```
初始化參數 θ, W；設定超參數 α, β, λ
for epoch t = 1 to T do
    前向計算所有 mini-batch，蒐集類別錯誤率 e_k^(t)
    依公式更新 w_k^(t)
    重新計算損失 L_cls 與類別中心 c_k
    計算 L_ortho 並反向傳遞更新參數
end for
輸出最終模型 f_θ
```

3.6 時間複雜度

正交化項計算複雜度為 $O(K^2 d)$，對於中等類別數可接受；若 K 大，可採隨機抽樣配對近似。

3.7 程式碼片段示例

以下示例展示權重計算之Python 風格偽程式：

```
def compute_weights(errors, counts, alpha, beta, eps=1e-4):
        # errors, counts: list of length K
        import math
        raw = [( (e + eps)**alpha ) / (c**beta) for e, c
            in zip(errors, counts)]
        s = sum(raw)
        return [v / s for v in raw]
```

Listing 第三章.1: 動態權重偽程式

第四章　實驗結果

本章說明實驗設定、評估指標、比較方法與結果分析。

4.1　實驗設定

資料集包含一組公開長尾影像集與一組自建小型資料。長尾程度以最大/最小類別樣本數比值(imbalance ratio) 表示，約為 100。模型以AdamW 優化器訓練 200 epochs，初始學習率 1×10^{-3} 並採餘弦退火。批次大小 64。

4.2　評估指標

使用 Top-1 Accuracy、Macro-F1 與少數 20

4.3　比較方法

比較基準包含：標準交叉熵(CE)、反頻率權重(InvFreq)、有效樣本權重(EffNum)與本研究 (Ours)。

4.4　主要結果

表 4-1 彙整主要結果，可見本研究在 Macro-F1 與 Minority Recall 皆優於其他方法。

表 4-1: 主要分類績效(公開資料集)

方法	Top-1(%)	Macro-F1(%)	Minority Recall(%)
CE	78.2	65.4	54.1
InvFreq	77.5	67.1	58.3
EffNum	78.0	68.0	59.5
Ours	**79.1**	**71.4**	**63.7**

4.5 消融研究

圖 4-1 顯示不同組件對 Macro-F1 之影響：僅動態權重 (DW) 或僅正交化 (Ortho) 均有提升，結合後最佳。

圖 4-1: 消融分析示意(示意圖以浮水印代替)。

4.6 特徵可視化

使用 t-SNE 將特徵嵌入投影至二維，結果顯示本研究方法之類別分群更為集中，異質類別重疊減少。

4.7 討論

本方法於少數類別提升較為顯著，但在極端噪聲標籤下需調降 λ 以避免過度正交化引入不穩定梯度。

第五章　結論

本研究提出結合動態類別重加權與特徵正交化之長尾影像分類框架。實驗顯示在維持整體 Top-1 準確率的同時，可顯著提升 Macro-F1 與少數類別召回率。分析證實正交化有助於降低類別間干擾，動態權重則自動聚焦較難類別。

未來方向包含：(1) 延伸至多標籤與開放集合辨識；(2) 與自監督特徵學習結合，降低標註需求；(3) 加入不確定性估計以處理噪聲標籤；(4) 探索低秩表示以降低額外計算成本。

參考文獻

[1] C. Li, K. Chang, H. Chang, and Y. Chen, “Perfect sequences of odd prime length,” *IEEE Signal Processing Letters*, vol. 25, no. 7, pp. 966–969, 2018.

[2] Y. Chen and J. Chen, “On the design of near-optimal sparse code multiple access codebooks,” *IEEE Transactions on Communications*, vol. 68, no. 5, pp. 2950–2962, 2020.

[3] M. Goossens, F. Mittelbach, and A. Samarin, *The LaTeX Companion*. Reading, Massachusetts: Addison-Wesley, 1993.

[4] D. Knuth, “Knuth: Computers and typesetting.”

附錄

附錄 A：正交化梯度推導

令兩類別中心單位化後之內積為 $r_{kj} = \frac{c_k^{\top} c_j}{\|c_k\| \, \|c_j\|}$。

$$L_{ortho} = \frac{1}{K(K-1)} \sum_{k \neq j} r_{kj}^2 . \tag{I}$$

對特徵向量 c_k 之梯度 (忽略常數) 為：

$$\nabla_{c_k} L_{ortho} \propto \sum_{j \neq k} r_{kj} \left(\frac{c_j}{\|c_k\| \, \|c_j\|} - r_{kj} \frac{c_k}{\|c_k\|^2} \right) . \tag{II}$$

此可做為計算效率與穩定性之參考。

附錄 B：額外結果

表與圖可於最終版補充更多資料集實驗，本文省略。

附錄 C：參考文獻引用示例

本模板採用natbib 套件並使用數字型引用。以下示例示範多種引用方式：

- 單一引用：如長尾分類相關工作可參考 [1]。
- 多篇合併：演算法與設計概念綜述可見 [1, 2]。
- 書籍或工具文件：排版細節說明請參考 [3]。
- 線上資源：[4] 提供更多 LaTeX 排版背景。

在正文中建議：首次提及理論時使用完整敘述+ 引用；再次出現僅保留必要引用。若需作者式引用（如“Chen 等人”），可改用 \citet 指令，但現行數字樣式下仍會以數字標示。若欲改為作者年份樣式，可調整 packages.tex 內 natbib 選項。